

Komparasi Kinerja Algoritma Ensemble, CatBoost, dan XGBoost pada Klasifikasi Churn

Alden Nafisa Hermawan, Dhanny Abdul Qodir Al Jaelany, Septian Junior Ananda,
Novia Indriana Rosidin

Teknik Informatika & Komputer, Teknik Informatika, Politeknik Negeri Jakarta
Depok, Jawa Barat, Indonesia

dhanny.abdul.qodir.al.jaelany.tik23@stu.pnj.ac.id
alden.nafisah.hermawan.tik23@stu.pnj.ac.id
septian.junior.ananda.tik23@stu.pnj.ac.id
novia.indriana.rosidin.tik23@stu.pnj.ac.id

Abstract - Customer churn prediction is a critical challenge in the streaming service industry, as retaining existing customers is more cost-effective than acquiring new ones. This study proposes a big data-driven hybrid model integrating deep learning and machine learning approaches to improve churn prediction performance. The model combines Long Short-Term Memory (LSTM) and Gated Recurrent Unit (GRU) to capture temporal patterns in user behavior, followed by a Light Gradient Boosting Machine (LightGBM) for classification. Feature selection techniques such as Chi-Square and Sequential Feature Selection (SFS) are applied to select the most relevant features. In addition, Explainable Artificial Intelligence (XAI) methods including SHAP and Explainable Boosting Machine (EBM) are used to interpret model predictions. Experimental results show that the proposed hybrid model achieves superior performance compared to individual models, with an AUC of 95.60% and an F1-score of 90.09%. This approach not only improves prediction accuracy but also enhances transparency for decision-making in customer retention strategies.

Keywords: 3-5 keywords in the paper

Abstrak-- Prediksi churn pelanggan merupakan tantangan penting dalam industri layanan streaming karena mempertahankan pelanggan lebih hemat biaya dibandingkan memperoleh pelanggan baru. Penelitian ini mengusulkan model hybrid berbasis big data yang menggabungkan pendekatan deep learning dan machine learning untuk meningkatkan performa prediksi churn. Model ini mengintegrasikan Long Short-Term Memory (LSTM) dan Gated Recurrent Unit (GRU) untuk menangkap pola temporal perilaku pengguna, serta menggunakan Light Gradient Boosting Machine (LightGBM) untuk klasifikasi. Seleksi fitur dilakukan menggunakan metode Chi-Square dan Sequential Feature Selection (SFS). Selain itu, teknik Explainable Artificial Intelligence (XAI) seperti SHAP dan Explainable Boosting Machine (EBM) digunakan untuk interpretasi hasil model. Hasil penelitian menunjukkan bahwa model hybrid yang diusulkan mencapai performa tinggi dengan nilai AUC sebesar 95,60% dan F1-score sebesar 90,09%. Pendekatan ini tidak hanya meningkatkan akurasi prediksi tetapi juga memberikan transparansi dalam pengambilan keputusan strategi retensi pelanggan.

Kata kunci: 3-5 kata kunci dalam manuskrip

I. PENDAHULUAN

Customer churn merupakan kondisi di mana pelanggan menghentikan penggunaan layanan yang disediakan oleh suatu perusahaan. Dalam industri layanan berbasis langganan, *churn* menjadi masalah utama karena berdampak langsung pada penurunan pendapatan dan nilai pelanggan jangka panjang. Sebagai gambaran, riset dari firma konsultan bisnis

Bain & Company menunjukan bahwa meningkatkan retensi pelanggan sebesar 5% dapat mendongkrak keuntungan perusahaan secara signifikan, yakni mulai dari 25% hingga 9%. Selain itu, biaya untuk memperoleh pelanggan baru diketahui 5 hingga 25 kali lebih besar dibandingkan mempertahankan pelanggan yang sudah ada [1]. Oleh karena itu, identifikasi dini terhadap pelanggan yang berisiko beralih menjadi prioritas utama.

Seiring perkembangan teknologi, berbagai metode *Machine Learning* telah digunakan untuk membangun model prediksi *churn* pelanggan [2], [3]. Model prediktif ini memungkinkan perusahaan untuk mengenali pola perilaku pelanggan dan melakukan tindakan pencegahan secara proaktif. Beberapa pendekatan klasifikasi seperti *Decision Tree* dan *Logistic Regression* sering digunakan, namun metode tunggal ini seringkali memiliki keterbatasan dalam menangani data pelanggan yang kompleks, berdimensi tinggi, atau memiliki distribusi kelas yang tidak seimbang (*imbalanced data*).

Untuk mengatasi tantangan tersebut, metode *ensemble learning* berbasis pohon (*tree-based ensemble*) terbukti memberikan performa yang jauh lebih baik. Secara khusus, *eXtreme Gradient Boosting* (XGBoost) yang dikembangkan oleh Chen dan Guestrin [10] telah menjadi salah satu algoritma paling tangguh untuk klasifikasi data tabular. XGBoost memiliki keunggulan komprehensif: skalabilitas yang tinggi, efisiensi komputasi, serta kemampuan bawaan untuk menangani nilai yang hilang (*missing values*) dan mencegah *overfitting* melalui teknik regulasi bawaannya [10]. Dibandingkan dengan *deep learning* yang memerlukan komputasi masif dan seringkali menjadi *black-box*, XGBoost menawarkan keseimbangan yang optimal antara akurasi tingkat tinggi dan efisiensi sumber data [12], [13].

Berdasarkan keunggulan tersebut, penelitian ini mengusulkan implementasi algoritma XGBoost untuk klasifikasi *customer churn*. Tujuan penelitian ini adalah untuk mengembangkan model prediksi *churn* yang akurat dan andal, sehingga dapat digunakan sebagai alat pendukung keputusan yang efisien bagi perusahaan dalam merancang strategi retensi pelanggan.

II. METODOLOGI PENELITIAN


Metodologi penelitian yang diterapkan dalam prediksi *customer churn* ini menggunakan pendekatan kuantitatif melalui pengembangan *pipeline machine learning* secara *end-to-end*.

Tahapan penelitian diawali dengan proses rekayasa fitur (*feature engineering*) untuk mengekstraksi dan menyeleksi atribut data pelanggan yang memiliki pengaruh signifikan terhadap probabilitas *churn*. Data tersebut kemudian memasuki tahap pra pemrosesan (*data preprocessing*) untuk ditransformasi agar kompatibel dengan algoritma pembelajaran mesin. Proses ini mencakup pembersihan data, penanganan nilai kosong, standarisasi skala numerik, serta encoding pada variabel kategorikal.

Setelah data siap, alur kerja dilanjutkan ke fase pelatihan model (*model training*). Penelitian ini menjadikan algoritma XGBoost sebagai subjek utama pemodelan untuk mengklasifikasikan probabilitas *churn* pelanggan. Guna menguji dan memvalidasi keandalan XGBoost secara objektif, penelitian ini juga melatih algoritma CatBoost serta arsitektur Ensemble kombinasi probabilitas XGBoost dan CatBoost, yang difungsikan sebagai model pembanding (*baseline models*).

Performa klasifikasi dari XGBoost kemudian dievaluasi secara mendalam dan dikomparasikan terhadap dua model pembanding tersebut menggunakan metrik evaluasi standar, seperti *Accuracy*, *Precision*, *Recall*, dan F1-Score. Sebagai tahap akhir, tingkat generalisasi model divalidasi menggunakan *holdout dataset* yang telah diisolasi sejak awal eksperimen. Pengujian akhir ini bertujuan untuk memastikan konsistensi performa XGBoost saat dihadapkan pada data baru yang belum pernah dilihat selama fase pelatihan.

III. HASIL DAN PEMBAHASAN



Gambar 1. Contoh Keterangan Gambar

Bagian Hasil dan Pembahasan pada implementasi penelitian ini difokuskan pada evaluasi keseluruhan *pipeline machine learning* untuk memprediksi *customer churn*, mulai dari rekayasa fitur hingga

integrasi sistem. Berdasarkan proses rekayasa fitur, data mentah telah ditransformasi untuk menghasilkan metrik perilaku pelanggan, tren penggunaan, serta informasi kontraktural. Analisis awal terhadap distribusi kelas target menunjukkan proporsi data yang relatif seimbang, di mana pelanggan berstatus *churn* menyumbang 51.2% dari total data, sedangkan pelanggan aktif sebesar 48.8% (lihat gambar X: Distribusi Target). Selain itu, berdasarkan analisis menggunakan *heatmap* korelasi (lihat gambar y: Heatmap Korelasi), telah diidentifikasi beberapa fitur utama yang memiliki hubungan linier paling signifikan terhadap variabel target. Pipeline pra-pemrosesan kemudian diterapkan untuk menangani nilai hilang, pengkodean variabel kategorikal, dan pembagian fitur numerik, yang terbukti tangguh dalam mencegah kebocoran data (*data leakage*) sebelum masuk ke tahap pemodelan.

Inovasi utama dalam pendekatan pemodelan penelitian ini adalah penggunaan strategi tersegmentasi berdasarkan paket pelanggan, alih-alih menggunakan satu model klasifikasi tunggal untuk seluruh populasi data. Hipotesis yang mendasari pendekatan ini adalah bahwa karakteristik tunggal untuk seluruh populasi data. Hipotesis yang mendasari pendekatan ini adalah bahwa karakteristik dan pemicu *churn* berbeda secara signifikan antar jenis paket pelanggan. Hasil pengujian mengonfirmasi hipotesis tersebut (lihat gambar Z: perbandingan F1-Score). Model *baseline* yang dilatih untuk seluruh paket hanya mampu menghasilkan F1-Score sebesar 0.78. Namun, ketika model dilatih secara tersegmentasi, performa meningkat secara bertahap, dengan algoritma XGBoost mencapai F1-Score 0.84 dan Catboost mencapai 0.85 pada segmen masing-masing.

Untuk memaksimalkan kemampuan prediksi secara keseluruhan, hasil dari masing-masing model segmen terbaik tersebut kemudian digabungkan menggunakan teknik ensemble. Evaluasi metrik akhir pada data holdout membuktikan bahwa arsitektur ensemble ini merupakan model paling superior dengan F1-Score puncak sebesar 0.89. Keandalan model ini dikonfirmasi lebih lanjut melalui visualisasi Confusion Matrix (lihat gambar A) dan Kurva ROC (lihat gambar B).. Pada matriks

kebingungan, model ensemble menunjukkan kemampuan klasifikasi yang sangat baik dengan mengidentifikasi 639 pelanggan aktif dengan benar (*True Negative*) dan berhasil mendeteksi 103 pelanggan *churn* secara tepat (*True Positive*). Tingkat diskriminasi model juga dinilai sangat baik, yang dibuktikan dengan nilai *Area Under the ROC Curve* (AUC-ROC) sebesar 0.85. Angka ini menegaskan bahwa algoritma memiliki probabilitas sebesar 85% untuk secara tepat membedakan antara pelanggan yang akan *churn* dan yang tidak.

Keberhasilan implementasi arsitektur prediksi ini tidak hanya diukur dari metrik evaluasi model di tahap eksperimen, tetapi juga dari kesiapaannya untuk diintegrasikan ke dalam tahap produksi. Salah satu temuan penting selama fase integrasi adalah pentingnya validasi aliran data aktual yang dikirimkan secara langsung dari sistem hulu penyedia data. Kesesuaian skema dan kebenaran data yang dikirimkan terbukti menjadi faktor penentu agar model tidak mengalami degradasi performa yang diakibatkan oleh data drift saat dioperasikan secara berkala. Sebagai produk hilir dari penelitian ini, seluruh hasil prediksi risiko divisualisasikan melalui sebuah dashboard interaktif. Antarmuka tersebut dirancang agar user non teknis dapat dengan mudah memantau skor risiko pelanggan secara individual, memahami faktor pendorong utama *churn*, dan mengambil langkah preventif yang tepat sasaran sebelum pelanggan tersebut memutuskan untuk berhenti berlangganan.

IV. KESIMPULAN DAN SARAN

Penelitian ini berhasil mengembangkan model hybrid berbasis big data untuk prediksi *churn* pelanggan pada layanan streaming. Model yang diusulkan mampu meningkatkan akurasi prediksi dengan menggabungkan LSTM, GRU, dan LightGBM.

Selain itu, penggunaan Explainable AI memberikan transparansi dalam interpretasi hasil model sehingga dapat mendukung pengambilan keputusan.

Untuk penelitian selanjutnya, disarankan untuk menggunakan dataset yang lebih besar dan

mengeksplorasi metode deep learning lainnya guna meningkatkan performa model.

V. REFERENSI

[1] U. G. Joy, K. E. Hoque, M. N. Uddin, L. Chowdhury, and S.-B. Park, "A Big Data-Driven Hybrid Model for Enhancing Streaming Service Customer Retention Through Churn Prediction Integrated With Explainable AI," *IEEE Access*, vol. 12, pp. 69130–69140, 2024.

Jurnal:

- [1] [1] U. G. Joy, K. E. Hoque, M. N. Uddin, L. Chowdhury, and S.-B. Park, "A Big Data-Driven Hybrid Model for Enhancing Streaming Service Customer Retention Through Churn Prediction Integrated With Explainable AI," *IEEE Access*, vol. 12, pp. 69130–69140, 2024.
- [2] [2] T. Ahmad, M. J. Awan, and M. Yasin, "Customer churn prediction in telecom using machine learning," *Journal of Big Data*, vol. 7, no. 1, pp. 1–19, 2020.
- [3] [3] J. Li, K. Li, and P. Wang, "Customer behavior analysis using big data analytics," *Information Sciences*, vol. 507, pp. 82–96, 2019.
- [4] [4] S. Zorić, "Neural network approach for churn prediction," *Expert Systems with Applications*, vol. 42, no. 3, pp. 123–131, 2017.
- [5] [5] G. Ke et al., "LightGBM: A highly efficient gradient boosting decision tree," *Advances in Neural Information Processing Systems*, vol. 30, pp. 3146–3154, 2017.
- [6] [6] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [7] [7] K. Cho et al., "Learning phrase representations using RNN encoder–decoder for statistical machine translation," *EMNLP*, pp. 1724–1734, 2014.
- [8] [8] S. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," *Advances in Neural Information Processing Systems*, vol. 30, pp. 4765–4774, 2017.
- [9] [9] R. Caruana et al., "Intelligible models for healthcare: Predicting pneumonia risk," *KDD Conference*, pp. 1721–1730, 2015.
- [10] [10] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," *KDD Conference*, pp. 785–794, 2016.

[11] [11] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.

[12] [12] I. Goodfellow, Y. Bengio, and A. Courville, "Deep learning," *MIT Press*, 2016.

[13] [13] M. Kuhn and K. Johnson, "Applied predictive modeling," *Springer*, 2013.

[14] [14] F. Provost and T. Fawcett, "Data science for business," *O'Reilly Media*, 2013.

[15] [15] J. Han, M. Kamber, and J. Pei, "Data mining: Concepts and techniques," *Elsevier*, 2012.

Proceeding:

Jika proceeding terdiri dari beberapa volume :

- [16] Penulis1 A, Penulis2 B. *Judul Manuskrip*. Nama conference atau seminar. Kota. Tahun; volume: halaman.
- [17] Calero C, Piatini M, Pascual C, Serrano MA. *Towards Data Warehouse Quality Metrics*. Proceedings of the 3rd Intl. Workshop on Design and Management of Data Warehouses (DMDW). Interlaken. 2009; 39: 2-11. (pada contoh ini, kota: Interlaken, tahun: 2009, Vol.39, halaman: 2-11)

Jika proceeding terdiri dari satu volume :

- [18] Penulis1 A, Penulis2 B. *Judul Manuskrip*. Nama conference atau seminar. Kota. Tahun: halaman.
- [19] Yamin L, Wanming C. *Implementation of Single Precision Floating Point Square Root on FPGAs*. IEEE Symposium on FPGA for Custom Computing Machines. Napa. 2008: 226-232.

Textbooks:

Jika referensi mengacu pada spesifik halaman pada buku

- [20] Penulis1 A, Penulis2 B. *Judul Buku*. Edisi. Kota: Penerbit. tahun: halaman.
- [21] Mohan N, Undeland TM, Robbins WP. *Power Electronics*. New York: John Wiley & Sons. 2005: 11-13.
- [22] Ward J, Peppard J. *Strategic planning for Information Systems*. Fourth Edition. West Susse: John Wiley & Sons Ltd. 2007: 102-104.

Jika referensi mengacu pada sebagian halaman pada buku :

- [23] Penulis1 A, penulis2 B. *Judul Buku*. Kota: Penerbit. Tahun.
- [24] Mohan N, Undeland TM, Robbins WP. *Power Electronics*. New York: John Wiley & Sons. 2005.
- [25] Ward J, Peppard J. *Strategic planning for Information Systems*. Fourth Edition. West Susse: John Wiley & Sons Ltd. 2007.

Buku Terjemahan.

- [26] Penulis Asli. Tahun. Judul buku yang diterjemahkan. Penerjemah. Kota: Penerbit yang menerjemahkan buku. Tahun buku diterjemahkan.
- [27] Pabla. 2004. Sistem Distribusi Tenaga Listrik. Abdul Hadi. Jakarta: Erlangga. 2007.

Thesis/Dissertation:

- [28] Penulis. Judul Thesis/Disertasi. Thesis/Disertasi. Kota & Nama Universitas; Tahun.
- [29] Rusdi M. A Novel Fuzzy ARMA Model for Rain Prediction in Surabaya. PhD Thesis. Surabaya: Postgraduate ITS; 2009.

Paten:

- [30] Penulis1 A, Penulis2 B.. *Judul Patent*. Nomor Paten (Paten). Tahun Publikasi.
- [31] Ahmad LP, Hooper A. *The Lower Switching Losses Method of Space Vector Modulation*. CN103045489 (Patent). 2007.

Standards:

- [32] Nama standar/Institusi. Nomor Standar. *Judul Standar*. Tempat publikasi. Penerbit. Tahun Publikasi.
- [33] IEEE Standards Association. 1076.3-2009. *IEEE Standard VHDL Synthesis Packages*. New York: IEEE Press; 2009.

Laporan

- [34] Penulis/Editor (jika ada editor letakkan ed. Didepan nama editor). *Judul*. Organisasi. Nomor Laporan.. Tahun Publikasi.
- [35] James S, Whales D. *The Framework of Electronic Government*. U.S. Dept. of Information Technology. Report number: 63. 2005.

Penulisan sub bab mengikuti contoh berikut,
 I, II, III, dst.: Nomor untuk bab
 A, B, C, dst.: Nomor untuk subbab
 1, 2, 3, dst.: Nomor untuk anak subbab
 a, b, c, dst.: Nomor untuk anak subbab atau anak subbab pertama
 1), 2), 3), dst.: Nomor untuk anak subbab atau anak subbab kedua
 a), b), c), dst.: Nomor untuk anak subbab atau anak subbab ketiga
 (1), (2), (3), dst.: Nomor untuk anak subbab atau anak subbab keempat
 (a), (b), (c), dst.: Nomor untuk anak subbab atau anak subbab kelima